

AgroSearch: Relatório Técnico

Motor de busca textual com TF-IDF implementado do zero para a AgroTech Solutions

1. Introdução

Os técnicos de campo da AgroTech Solutions perdiam tempo procurando informações específicas em manuais técnicos sobre agricultura sustentável, controle de pragas e irrigação. Este projeto entrega um protótipo de motor de busca textual, o AgroSearch, que recebe uma consulta digitada pelo técnico e retorna os trechos mais relevantes da base de documentos, ranqueados por relevância. Todo o processamento de texto e o cálculo de relevância foram implementados manualmente, sem bibliotecas de alto nível como scikit learn ou TfidfVectorizer, conforme exigido pelo enunciado.

2. Metodologia e Pipeline

O pipeline de pré processamento segue quatro etapas aplicadas em sequência a cada documento e à consulta do usuário: (1) **Tokenização**, via expressão regular que extrai sequências de letras; (2) **Normalização**, com conversão para minúsculas e remoção de acentuação (unicodedata, forma NFKD); (3) **Remoção de Stopwords**, opcional via checkbox, usando uma lista curta de palavras funcionais do português (artigos, preposições, conjunções); (4) **Stemming**, também opcional, implementado como um stemmer por remoção de sufixo: uma lista de sufixos comuns do português (ex.: 'ção', 'mente', 'ando', 'adores') é testada do maior para o menor, removendo o primeiro que casar, desde que o radical resultante tenha ao menos 3 caracteres.

Com os tokens de cada documento em mãos, o **índice invertido** é construído associando cada termo ao conjunto de IDs de documentos em que ele aparece, e é exibido dinamicamente na interface via st.json, refletindo em tempo real qualquer mudança nas opções de stopwords e stemming.

Para o ranqueamento, três métricas foram implementadas do zero:

- **TF**(termo, doc) igual ao número de ocorrências do termo no doc dividido pelo número total de termos do doc, a frequência normalizada pelo tamanho do documento.
- **IDF**(termo) igual a $\log\left(\frac{N}{df}\right)$, onde N é o número total de documentos da coleção e df é o número de documentos que contêm o termo. Termos raros, com df baixo, recebem peso maior.
- **TF-IDF**(termo, doc) igual a TF(termo, doc) multiplicado por IDF(termo).

Para uma consulta, o sistema soma o TF-IDF de cada termo da query presente em cada documento, formando um score acumulado, e ordena o resultado de forma decrescente, destacando o documento vencedor.

3. Desafio Bônus

Como alternativa de ranqueamento, ativável via checkbox, foi implementada a Similaridade de Cosseno. A query é convertida em um vetor TF-IDF usando o mesmo IDF calculado sobre o corpus, e a similaridade entre o vetor da query e o vetor de cada documento é calculada como o produto escalar entre os dois vetores dividido pelo produto das suas normas, tratando os vetores como dicionários esparsos com apenas os termos não nulos. Essa abordagem evita divisão por zero em documentos ou queries sem termos em comum e lida melhor com consultas de múltiplas palavras do que a simples soma de TF-IDF.

4. Resultados e Interface

A aplicação é um único arquivo, agrosearch.py, organizado em três seções visíveis na tela, na mesma ordem do pipeline: pré processamento (checkboxes de stopwords e stemming, vocabulário e tokens por documento), índice invertido (st.json) e busca com ranqueamento (campo de texto, tabela ordenada com gradiente de cor pelo score e destaque do documento vencedor via st.success). Como validação, a consulta 'irrigação soja' foi testada e corretamente ranqueou o Doc 1 em primeiro lugar, único documento da base que contém ambos os termos simultaneamente, confirmando o funcionamento correto do pipeline, do índice invertido e do cálculo de TF-IDF de ponta a ponta.

5. Trabalho de Equipe e Divisão de Tarefas

O projeto foi desenvolvido individualmente por Hiago Kalil Silva do Nascimento, responsável por todas as etapas descritas neste relatório: o pipeline de pré processamento (tokenização, normalização, remoção de

stopwords e stemmer construído do zero), o índice invertido, o cálculo manual de TF, IDF e TF-IDF, o ranqueamento dos documentos, o desafio bônus de similaridade de cosseno e a construção completa da interface em Streamlit.

6. Conclusão

O AgroSearch cumpre o objetivo proposto de recuperar, a partir de uma consulta em linguagem natural, os trechos mais relevantes de uma base de manuais técnicos, sem depender de bibliotecas prontas de recuperação de informação. A implementação do pipeline de pré processamento, do índice invertido e do TF-IDF do zero consolidou o entendimento matemático e prático por trás dessas técnicas, enquanto o desafio bônus de similaridade de cosseno mostrou como refinar o ranqueamento para consultas com múltiplos termos. Como próximos passos, a base de documentos poderia ser expandida e o stemmer refinado com mais regras linguísticas para lidar com um vocabulário mais amplo.